# MOTEURS DE RECOMMANDATION (Recommender systems)

# INTRODUCTION

**Objectif** : proposer aux utilisateurs des choix **pertinents**.

**Applications nombreuses.** En particulier : produits culturels (Amazon, Netflix), publicité (Criteo, Facebook), réseaux sociaux (Facebook, LinkedIn, Pinterest, YouTube), recherche Web (Google, Bing), sites de rencontres (Meetic)...

**Principe intuitif** : utilisation des caractéristiques de l'utilisateur et/ou des produits pour proposer des choix parmi un catalogue de choix possibles.

Cours plus poussé de M. Habib.

# EXEMPLE

Quelle méthode utiliser pour proposer à des étudiants de M2 informatique des cours qui les intéresseraient?

"Les étudiants qui ont pris ce cours ont pris ces cours..."

Le cours de Fouille de Données a des **mots-clés similaires** à ceux du cours de moteurs de recherche : si on aime l'un, on devrait aimer l'autre.

L'utilisateur **ressemble** à un utilisateur qui a aimé le cours de fouilles de données. Il devrait l'aimer aussi.

L'utilisateur **aime les mêmes cours** qu'un utilisateur qui a aimé le cours de fouilles de données. Il devrait l'aimer aussi.

**Différents systèmes, tous pertinents mais pas forcéments dans les mêmes contextes !**

# DEUX MODÈLES PRINCIPAUX

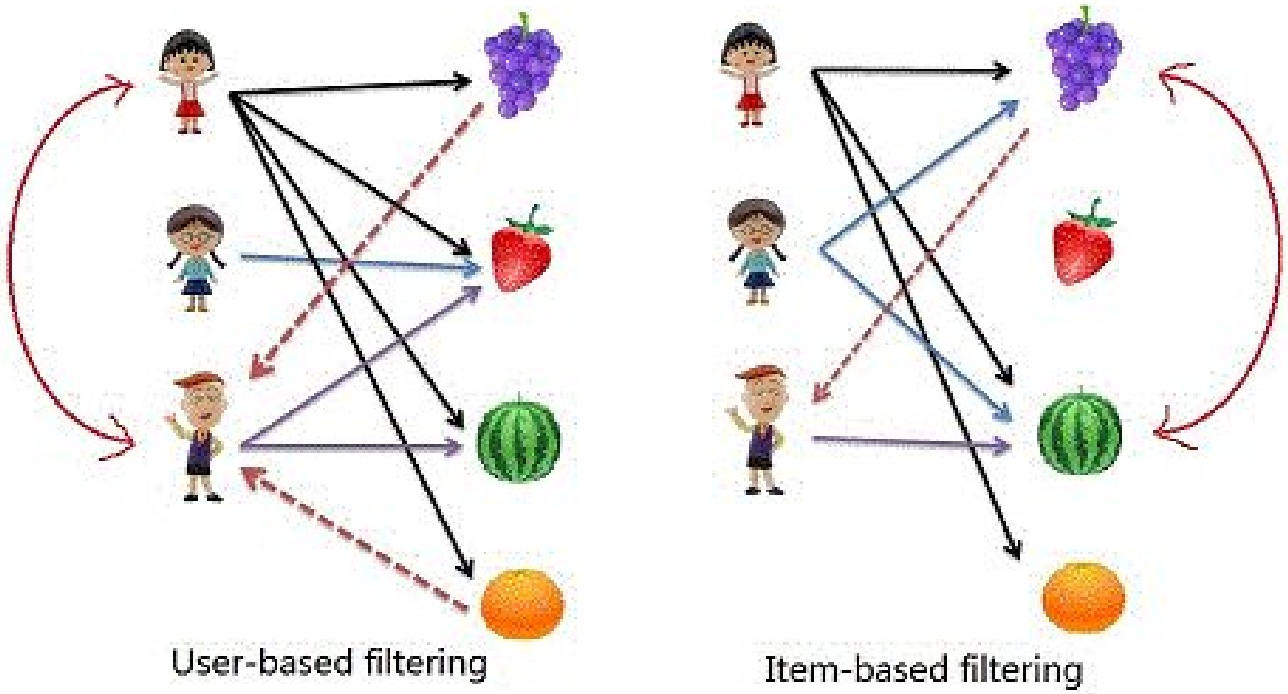


*Source : paxcel.net*

**User-based** : basé sur les utilisateurs

**Content- ou Item-based** : basé sur le contenu

# ALGORITHMES BASÉS SUR LE CONTENU

# PRINCIPE


| | | | | |
|---|---|---|---|---|
| Camille | 4 | 5 | ? | 4 |
| Mehdi | 1 | ? | 5 | ? |
| Julien | 5 | ? | ? | 2 |

On modélise:

D'une part : le **profil-utilisateur**, i.e. les contenus qu'il a aimés.

D'autre part, les nouveaux contenus.

**Objectif : donner une note aux nouveaux contenus en fonction des anciens.**

# MODÉLISATION DES CONTENUS

On cherche à repérer ce qui **caractérise** un contenu parmi les autres.
Souvent, on va donc utiliser un modèle **TF-IDF** qui met en avant l'originalité du contenu par rapport à un ensemble de contenus.
Une autre manière de faire est d'extraire des **mots-clés** du contenu (mais en général, on s'aide aussi d'un TF-IDF).

# EXEMPLE

Un étudiant aime le cours de fouille de données (ce qui est normal). Ce cours, **comparé aux autres**, a de fortes valeurs TF-IDF pour les mots : données, fouille, intelligence, apprentissage, statistiques.
En revanche, il a des faibles valeurs TF-IDF pour les mots : algorithme (qui apparaît dans beaucoup de cours), systèmes, architecture, etc.

On mesure la **similarité** entre le TF-IDF du cours "Fouille de données" avec celui de chacun des autres cours.

On propose à l'étudiant des cours similaires, comme "Moteurs de recherche", qui a un **profil** similaire.

# CALCUL DE LA SIMILARITÉ

| | algorithme | systeme | statistique | donnees |
|---|---|---|---|---|
| FDD | 0.1 | 0.05 | 3.5 | 3 |
| MDR | 0.1 | 1.2 | 2 | 2 |
| SA | 0.05 | 4 | 0 | 1 |

(Données non réelles)

On peut mesurer une **distance** entre chaque couple de cours et l'ordonner par ordre croissant.

On peut calculer d'autres **similarités**, que nous allons voir maintenant.

# SIMILARITE “COSINUS”

Si x et y sont deux vecteurs TF-IDF, la **similarité cosinus** entre eux est :

$$S(x,y) = \frac{\langle x, y \rangle}{||x|| \times ||y||} = \frac{\sum_{i=1}^{n} x_i y_i}{\sqrt{\sum_{i=1}^{n} x_i^2} \sum_{i=1}^{n} y_i^2}$$

# SIMILARITE “COSINUS”

Si x et y sont deux vecteurs TF-IDF, la **similarité cosinus** entre eux est :

$$S(x,y) = \frac{\langle x, y \rangle}{||x|| \times ||y||} = \frac{\sum_{i=1}^{n} x_i y_i}{\sqrt{\sum_{i=1}^{n} x_i^2} \sum_{i=1}^{n} y_i^2}$$

- <x, y> est le produit scalaire entre x et y. Par exemple:

<FDD, MDR> = 0.1 x 0.1 + 0.05 x 1.2 + 3.5 x 2 + 3 x 2 = 13.07

- ||x|| est la norme de x. C’est aussi la racine du produit scalaire de x avec lui-même. Elle représente la “taille” de x.
- Le numérateur est grand si x et y ont de grandes valeurs aux mêmes endroits.
- Pour éviter un effet taille, on divise par le produit des normes.

# SIMILARITÉ COSINUS - SUITE

En réalité, on voudrait calculer **l'angle** entre les deux documents. Mais en pratique, il est plus simple de calculer le cosinus.

**Plus l'angle est faible, plus le cosinus est grand** : cos(0) = 1 pour deux vecteur identiques, cos(90) = 0 pour deux vecteurs indépendants.

*Exemple : x = (0, 1, 2, 0), y = (0, 1, 2, 0), z = (1, 0, 0, 1) :*
*cos(x , y ) = 1et cos(x,z) = 0.*
En pratique, cette similarité se trouvera toujours entre 0 et 1 car on ne considère que des termes positifs.

Donc il sera facile de savoir si deux documents se ressemblent:

0 : aucune ressemblance
1 : documents identiques
0.5: ressemblance moyenne

# SIMILARITÉ DE DICE-SORENSEN

Si A et B sont deux ensembles de mots-clés, la **similarité de Dice** entre eux est :

$$S(A,B) = \frac{2|A \cap B|}{|A| + |B|} = 2 \times \frac{\text{Nombre de mots en commun}}{\text{Nombre total de mots}}$$

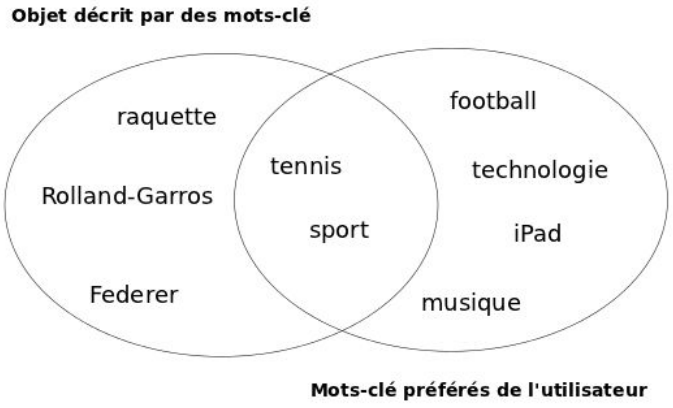


Exemple: ici,

$$S(A,B) = \frac{2 \times 2}{5 + 6}$$

Source : podcastscience.fm

# MODÉLISATION DU PROFIL METHODE 1

Supposons qu'un utilisateur ait consulté, ou, mieux, "liké" quatre documents A, B, C et D. On veut mesurer son **profil**.
Le plus simple est de regarder la **moyenne** de ce qu'il aime:

$$P = \frac{TFIDF(A) + TFIDF(B) + TFIDF(C) + TFIDF(D)}{4}$$

On obtient alors un vecteur de ses **goûts moyens**.
Ce vecteur P est celui qui est comparé aux nouveaux contenus. Les contenus les plus proches de P sont proposés à l'utilisateur.
**Inconvénient** : s'il aime des choses très différentes, faire leur moyenne n'a aucun sens !

# MODÉLISATION DU PROFIL MÉTHODE 2

On commence par **clusteriser** les contenus passés. Par exemple, on trouve que A et B forment un cluster et que C et D en forment un autre.
Pour chaque nouveau contenu, on regarde la **similarité avec chaque cluster**, en utilisant la méthode que l'on veut : distance minimale, maximale, moyenne, Ward ou encore similarité cosinus avec la moyenne de chaque cluster.
Ainsi, on est sûr de ne moyenner que des **contenus comparables**.

# ALGORITHME

**Algorithm 1** Recommandation basée sur le contenu

1: **Initialisation** : X : matrice composée de vecteurs TF-IDF ou mots-clés des contenus passés aimés de l'utilisateur.
2: **for** Chaque visite sur le site **do**
3: Calculer le profil-utilisateur avec la méthode 1 ou 2;
4: Trouver le produit le plus similaire au profil-utilisateur;
5: **if** L'utilisateur aime ce contenu **then**
6: Il est ajouté à X ;
7: **end if**
8: **end for**

# LE PROBLÈME DU COLD START

On parle de **cold-start** lorsque l'on ne connaît pas du tout l'utilisateur et qu'il n'a aimé aucun contenu.

On est alors obligé de lui proposer des contenus choisis **au hasard**.

# RECOMMANDATION PAR CONTENU: CONCLUSION

**Avantages :**

L'algorithme fait des propositions personnalisées.

Il ne requiert pas la participation de milliers d'utilisateurs.

**Inconvénients :**

L'algorithme ne se base que sur le profil-utilisateur, il ne prend pas en compte les autres utilisateurs.

Il ne répond pas au problème du cold-start.

Certains types de contenus (subjectifs) sont difficiles à comparer.

# ALGORITHMES BASÉS SUR LES UTILISATEURS

# PRINCIPE

On part du principe que les utilisateurs ayant aimé les mêmes choses dans le passé aimeront les mêmes choses dans le futur.

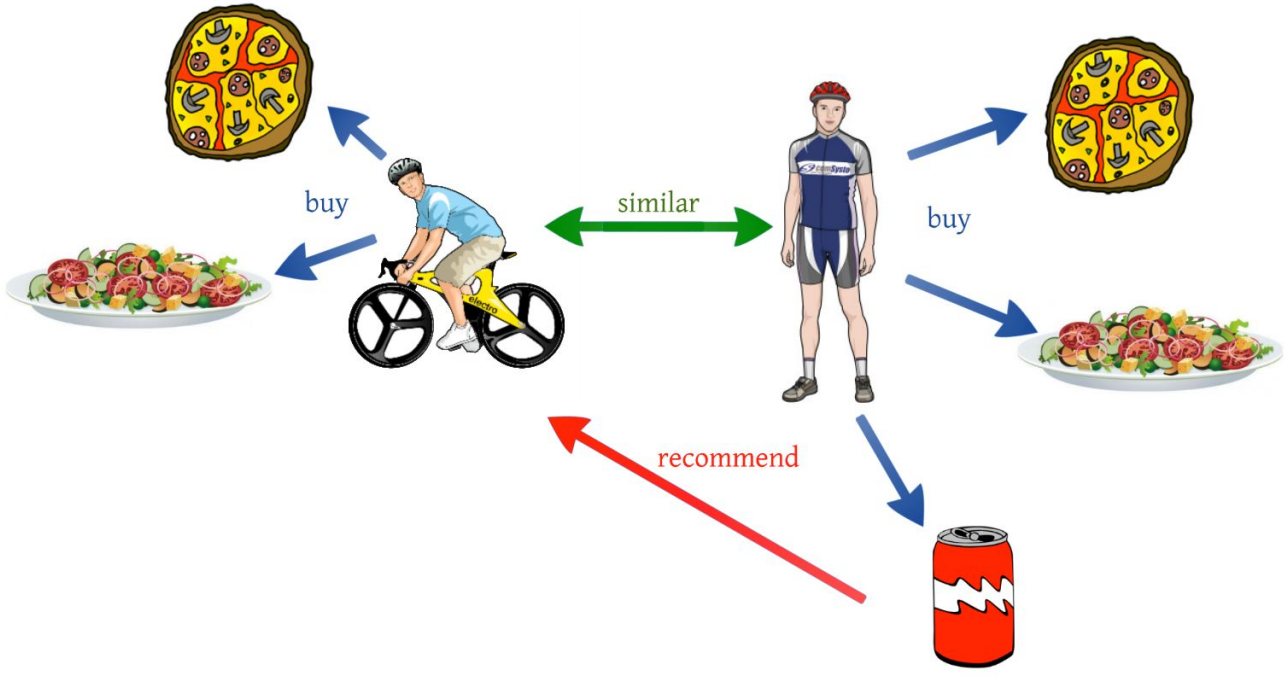


*Source : blog.comsysto.com*

On parle de **collaborative filtering**.

# PROBLÈME DE DÉPART

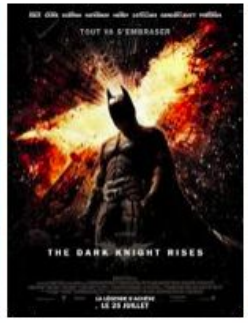


| | | | | |
|---|---|---|---|---|
| Camille | 4 | 5 | ? | 4 |
| Mehdi | 1 | ? | 5 | ? |
| Julien | 5 | ? | ? | 2 |

On cherche à **remplir les cases inconnues**.

# SIMILARITÉ DES UTILISATEURS

Si x et y sont deux utilisateurs représentés par leur vecteur de goûts, alors la similarité entre eux est mesurée par le **coefficient de corrélation** :

$$\rho(x,y) = \frac{\sigma_{xy}}{\sigma_x \sigma_y} = \frac{\sum_i (x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_i (x_i - \overline{x})^2} \sqrt{\sum_i (y_i - \overline{y})^2}}$$

$\sigma_x$ et $\sigma_y$ sont les **écarts-type** de x et y. Ils mesurent la variance, la variabilité de chacun des utilisateurs.
$\sigma_{xy}$ est la **covariance** entre x et y. Elle décrit le comportement d'une des deux variables en fonction de l'autre. Par exemple, une covariance positive signifie que x et y varient dans le même sens.
La **corrélation** ρ se trouve entre −1 (opposés) et 1 (identiques).

# GESTION DES DONNÉES MANQUANTES

Comment mesurer la corrélation entre deux utilisateurs si certaines "cases" sont vides?

**Solution 1**: ne prendre en compte que les "lignes" complètes pour les deux utilisateurs.

**Solution 2**: remplacer les cases manquantes par la moyenne des notes des utilisateurs.


| | | | | |
|---|---|---|---|---|
| Camille | 4 | 5 | ? | 4 |
| Mehdi | 1 | ? | 5 | ? |
| Julien | 5 | ? | ? | 2 |

0.7
0.6
0.2

*Source : podcastscience.fm.*

D'autres solutions existent mais elles sont beaucoup plus compliquées !

# PROPOSITION DE CONTENUS

On commence par **calculer la corrélation** entre l'utilisateur-cible et tous les autres.
Les valeurs de corrélation sont alors utilisées comme des poids pour calculer une **moyenne pondérée** de leurs notes (ratings) pour chaque nouveau contenu.
Cette moyenne pondérée est utilisée pour **prédire une note** utilisateur-cible/nouveau contenu.

# EXEMPLE

| | Etudiant 0 | Etudiant 1 | Etudiant 2 |
|---|---|---|---|
| Systèmes avancés | 0 | 1 | 0 |
| Bases de données | 1 | 1 | 1 |
| Fouille de données | 1 | 0 | ? |
| Moteurs de recherche | 1 | 0 | 1 |
| XML | 1 | 0 | 0 |

**L'étudiant 2 va-t-il aimer le cours de Fouilles de Données ?**

```
E   = np.array([[0,1,1,1],[1,1,0,0],[0,1,1,0]])
C   = np.corrcoef(E)
print C
   [[  1.          -0.57735027   0.57735027]
    [-0.57735027   1.           0.          ]
    [ 0.57735027   0.           1.          ]]
rating  =  C[0,2]*  1  +  C[1,2]*  0
print rating
   0.57735026919
```

# VARIANTE

| | Etudiant 0 | Etudiant 1 | Etudiant 2 |
|---|---|---|---|
| Systèmes avancés | 1 | 3 | 0 |
| Bases de données | 5 | 4 | 4 |
| Fouille de données | 4 | 1 | ? |
| Moteurs de recherche | 4 | 2 | 1 |
| XML | 5 | 1 | 1 |

**L'étudiant 2 va-t-il aimer le cours de Fouilles de Données ?**

```
E = np.array([[1,5,4,5],[3,4,2,1],[0,4,1,1]])
C = np.corrcoef(E)
print C
    [[  1.          -0.2045983    0.66082714]
     [-0.2045983     1.           0.59628479]
     [ 0.66082714   0.59628479   1.          ]]
rating = C[0,2]*  4  +  C[1,2]*  1
print rating
    3.23959334643175
```

# PROBLEME DE COLD START

Ici, le problème de **cold-start** revient à avoir un ligne entière vide (cold-start item) ou un colonne entière vide (cold-start user).

Dans beaucoup de cas, on va donc demander aux utilisateurs de donner des ratings **explicitement**.


*Source : bogost.com*

# PROBLÈMES DE CALCUL

Si, comme Netflix, on a des dizaines de millions d'utilisateurs, le calcul **en temps réel** devient trop lourd.
On va donc **précalculer off-line** les similarités.

On choisit les K utilisateurs **plus proches voisins** (K-nearest neighbors), c'est-à-dire les K utilisateurs ayant les plus fortes corrélations avec l'utilisateur-cible.
On ne calcule le rating qu'à partir de ces K utilisateurs.

**Variante** : on pré-sélectionne les utilisateurs ayant une corrélation supérieure à c avec l'utilisateur-cible.
Idée sous-jacente : les autres sont négligeables.

# USER-CENTRIC VS ITEM-CENTRIC

L'approche qu'on vient de voir compare d'abord les utilisateurs. On l'appelle **user-centric**.

On peut inverser les calculs en calculant les similarités sur les contenus (**item-centric**) : deux contenus avec les mêmes ratings utilisateurs ont une similarité 1.
Si un utilisateur aime un contenu, on lui propose un contenu corrélé.

L'approche item-centric est moins gloutonne et permet le temps réel.

C'est l'approche inventée par **Amazon**.
Attention : cette approche est différente de la recommandation par contenu seulement qui n'utilise pas les notes des utilisateurs.

# COLLABORATIVE FILTERING: CONCLUSION

**Avantages**:

Pas besoin de connaissance sur le contenu : on ne se base que sur les notes des utilisateurs.
Il est donc plus facile à implémenter.

**Inconvénients**:

Calculs lourds.

Problèmes de cold-start non résolus.

**Sparsity** (parcimonie, rareté) : sur un site comme Amazon, il y a des millions de produits. Les utilisateurs n'en noteront qu'une minuscule partie => beaucoup de valeurs manquantes.

# AUTRES MÉTHODES

# RECOMMANDATION PERSONALISÉE

Approche basée sur le comportement passé de l'utilisateur (clics, recherches Google, likes...). On va simplement lui recommander des contenus en fonction de ce qu'il a déjà cherché.

Exemples : AdSense, Criteo

# RECOMMANDATION HYBRIDE

La **recommandation hybride** se base sur les 3 approches précédentes. Elle combine donc les actions passées de l'utilisateur, les similarités entre contenus et le collaborative filtering.
Bien sûr, elle est plus performante que n'importe laquelle des autres seulement. Elle permet de résoudre les problèmes de cold-start et de sparsity.
**En pratique**, on peut par exemple pré-remplir la matrice de collaborative filtering avec un algorithme basé sur le contenu et l'historique de l'utilisateur.
C'est l'approche utilisée par Google, Amazon et Netflix.

# EXEMPLE: YOUTUBE OU NETFLIX

**Recommandation personnalisée** : en fonction de l'historique et de nos caractéristiques sociales (localisation, âge, etc.)

**Recommandation basée sur le contenu** : les vidéos ont des tags similaires

**Collaborative filtering** : les utilisateurs qui ont aimé la vidéo que vous regardez ont aussi aimé ces autres vidéos.

**Concrètement, on peut mettre des poids ou des priorités à chacun de ces types pour le ranking final.**

# EVALUATION

Deux métriques vous intéressent:

- RECALL: Parmi les contenus que la personne a aimés, combien étaient dans ma liste de recommandation?
- PRÉCISION: Parmi les contenus que j'ai proposés à cette personne, combien en a-t-elle aimés?

L'algorithme parfait a une précision de 1 et un recall de 1: non seulement la personne adore tout ce que vous lui proposez (précision maximale) mais en plus elle n'aime rien d'autre (recall maximal). Le problème c'est que pour faire augmenter l'un, on prend le risque de baisser l'autre.

# EVALUATION

Je propose des vidéos de:
- chat mignon (score 0.95)
- chat possédé (score 0.92)
- chat qui tombe d'une chaise (score 0.9)
- chat qui vole (score 0.8)
- chat qui joue au foot (score 0.7)
- … (100 autres vidéos)
- chat jouant avec un chien (0.6)

La personne clique sur:
- chat qui joue au foot
- chat mignon
- chat jouant avec un chien
- chat qui tombe d'une chaise
- 10 autres vidéos qui ne sont pas dans ma liste ou avaient un score < 0.6

| | | |
|---|---|---|
| Au seuil 0.9, | mon recall est de : 2 / 14, | ma précision de 2 / 3 |
| Au seuil 0.7, | mon recall est de : 3 / 14, | ma précision de 3 / 5 |
| Au seuil 0.6, | mon recall est de : 4 / 14, | ma précision de 4 / 106 |

# EVALUATION

On peut prendre le problème à l'envers:

Pour avoir une précision de 0.9, combien faut-il que je recommande d'objets? Et est-ce possible dans l'absolu? Cela peut déterminer la taille de votre liste.

# EVALUATION

D’autres métriques sont utilisées pour renforcer l’idée que le haut de la liste est le plus important:


- AP (Average precision):

AP = ⅓(1/1 + 2/2 + 3/ 5) = 0.87

- NDCG (Normalized Discounted Cumulative Gain):

DCG = 1 + 1/log2(2) + 1/log2(5) = 2.43

IDCG = 1 + 1/log2(2) + 1/log2(3) = 2.63 => Idealized DCG

NDCG = DCG / IDCG = 2.43 / 2.63 = 0.92

Si l’utilisateur donne des notes, on remplace les “1” des numérateurs par les notes données.

# EVALUATION - EN PRATIQUE

Deux solutions, ou plutôt deux étapes:

- laisser de côté certains contenus aimés de l'utilisateur pour créer votre modèle. Pour évaluer, il suffit de regarder si les contenus ignorés sont dans votre liste et de calculer recall/précision dessus.
- votre moteur est en ligne. Attendre le feedback de l'utilisateur sur vos recos pour continuer d'enrichir et d'évaluer votre modèle.

# CLUSTERING VS RECOMMANDATION

Attention : ce ne sont pas les mêmes choses ! Il ne faut pas les confondre.

Ces deux types d'algorithmes n'ont en commun que l'utilisation de **distances** entre objets. (Et parfois le clustering est utilisé dans le cadre de la recommandation):

- **Clustering** : algorithmes **non supervisés** dont le but est de grouper des objets dans des classes.
- **Recommandation** : algorithmes qui utilisent des informations données par les utilisateurs pour leur proposer d'autres choix.

# CONCLUSION

En fonction du problème et surtout du type de données, on choisit un algorithme approprié.

- Croyances... Croyez-vous qu'il soit pertinent de proposer des contenus en fonction de ce qu'ont aimé les autres ? Si oui, le collaborative filtering a un sens. Sinon, il faut utiliser autre chose. Cela dépend également du type de contenu.
- Algorithmes fructueux : en 2009, Amazon annonçait que 30% de son CA était obtenu via de la recommandation !
- Algorithmes customisables : le bon sens et les idées "non-mathématiques" en général vont jouer un rôle important.