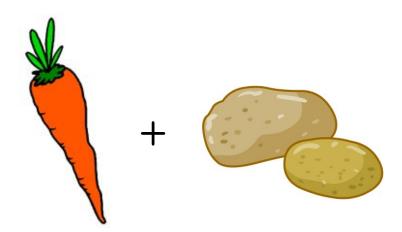
École Normale Supérieure

Langages de programmation et compilation

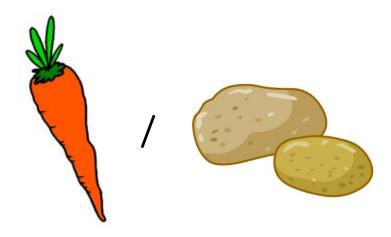
Jean-Christophe Filliâtre

Cours 4 / 13 octobre 2017

typage



typage



si j'écris l'expression

dois-je obtenir

- une erreur à la compilation? (OCaml, Rust)
- une erreur à l'exécution? (Python)
- l'entier 42? (Visual Basic, PHP)
- la chaîne "537" ? (Java)
- un pointeur? (C, C++)
- autre chose encore?

et qu'en est-il de

37 / "5"

et si on additionne deux expressions arbitraires

$$e1 + e2$$

comment déterminer si cela est légal et ce que l'on doit faire le cas échéant?

la réponse est le **typage**, une analyse qui associe un **type** à chaque sous-expression, dans le but de rejeter les programmes incohérents

à quel moment?

certains langages sont **typés dynamiquement**, c'est-à-dire pendant l'exécution du programme

exemples: Lisp, PHP, Python

d'autres sont **typés statiquement**, c'est-à-dire pendant la compilation du programme

exemples : C, Java, OCaml, Rust

c'est ce second cas que l'on considère dans ce cours

slogan

well typed programs do not go wrong

objectifs du typage

- le typage doit être décidable
- le typage doit rejeter les programmes absurdes comme 1 2, dont l'évaluation échouerait; c'est la sûreté du typage
- le typage ne doit pas rejeter trop de programmes non-absurdes, i.e. le système de types doit être expressif

plusieurs solutions

1. toutes les sous-expressions sont annotées par un type

$$fun(x:int) \rightarrow let(y:int) = (+:)(((x:int),(1:int)):int\times int)$$
 facile de vérifier mais trop fastidieux pour le programmeur

2. annoter seulement les déclarations de variables (Pascal, C, Java, etc.)

fun
$$(x:int) \rightarrow let (y:int) = +(x,1) in y$$

3. annoter seulement les paramètres de fonctions

$$\texttt{fun}\;(x:\texttt{int})\to \texttt{let}\;y=+(x,1)\;\texttt{in}\;y$$

4. ne rien annoter ⇒ inférence complète (OCaml, Haskell, etc.)

propriétés attendues

un algorithme de typage doit avoir les propriétés de

- **correction** : si l'algorithme répond "oui" alors le programme est effectivement bien typé
- complétude : si le programme est bien typé, alors l'algorithme doit répondre "oui"

et éventuellement de

 principalité : le type calculé pour une expression est le plus général possible

typage de mini-ML

considérons le typage de mini-ML

- 1. typage monomorphe
- 2. typage polymorphe, inférence de types

rappel

```
\begin{array}{lll} e & ::= & x & & \text{identificateur} \\ & | & c & & \text{constante } (1,\,2,\,\ldots,\,\textit{true},\,\ldots) \\ & | & op & & \text{primitive } (+,\,\times,\,\textit{fst},\,\ldots) \\ & | & \text{fun } x \rightarrow e & & \text{fonction} \\ & | & e & & \text{application} \\ & | & (e,e) & & \text{paire} \\ & | & \text{let } x = e \text{ in } e & \text{liaison locale} \end{array}
```

typage monomorphe de mini-ML

on se donne des types simples, dont la syntaxe abstraite est

jugement de typage

le jugement de typage que l'on va définir se note

$$\Gamma \vdash e : \tau$$

et se lit « dans l'environnement Γ , l'expression e a le type τ »

l'environnement Γ associe un type $\Gamma(x)$ à toute variable x libre dans e

règles de typage

$$\Gamma + x : \tau$$
 est l'environnement Γ' défini par $\Gamma'(x) = \tau$ et $\Gamma'(y) = \Gamma(y)$ sinon

 $\frac{\Gamma \vdash e_1 : \tau_1 \quad \Gamma \vdash e_2 : \tau_2}{\Gamma \vdash (e_1, e_2) : \tau_1 \times \tau_2} \qquad \frac{\Gamma \vdash e_1 : \tau_1 \quad \Gamma + x : \tau_1 \vdash e_2 : \tau_2}{\Gamma \vdash \mathsf{let} \ x = e_1 \ \mathsf{in} \ e_2 : \tau_2}$

exemple

$$\frac{\vdots \quad \frac{\vdots}{x: \mathtt{int} \vdash (x,1): \mathtt{int} \times \mathtt{int}}}{x: \mathtt{int} \vdash +(x,1): \mathtt{int}} \quad \frac{}{x: \mathtt{int} \vdash +(x,1): \mathtt{int}} \quad \frac{}{f: \mathtt{int} \to \mathtt{int}} \quad \frac{}{f: \mathtt{int} \to \mathtt{int}} \quad \frac{}{x: \mathtt{int} \vdash f : \mathtt{int}}$$

expressions non typables

en revanche, on ne peut pas typer le programme 1 2

$$\frac{\Gamma \vdash \mathbf{1} : \tau' \to \tau \qquad \Gamma \vdash \mathbf{2} : \tau'}{\Gamma \vdash \mathbf{1} \ \mathbf{2} : \tau}$$

ni le programme fun $x \rightarrow x$ x

$$\frac{\Gamma + x : \tau_1 \vdash x : \tau_3 \to \tau_2 \qquad \Gamma + x : \tau_1 \vdash x : \tau_3}{\Gamma + x : \tau_1 \vdash x : \tau_2}$$

$$\frac{\Gamma + x : \tau_1 \vdash x : \tau_2}{\Gamma \vdash \text{fun } x \to x : \tau_1 \to \tau_2}$$

car $\tau_1 = \tau_1 \rightarrow \tau_2$ n'a pas de solution (les types sont finis)

plusieurs types possibles

on peut montrer

$$\emptyset \vdash \mathtt{fun} \ x \to x : \mathtt{int} \to \mathtt{int}$$

mais aussi

$$\emptyset \vdash \mathtt{fun} \ x \to x : \mathtt{bool} \to \mathtt{bool}$$

attention : ce n'est pas du polymorphisme

pour une occurrence donnée de fun $x \to x$ il faut choisir un type

plusieurs types possibles

ainsi, le terme let $f=\operatorname{fun} x\to x$ in $(f\ 1,f\ \operatorname{true})$ n'est pas typable car il n'y a pas de type τ tel que

$$f: \tau \to \tau \vdash (f \ 1, f \ \mathsf{true}) : \tau_1 \times \tau_2$$

en revanche,

$$((\operatorname{fun} x \to x) (\operatorname{fun} x \to x))$$
 42

est typable (exercice : le montrer)

en particulier, on ne peut pas donner un type satisfaisant à une primitive comme fst; il faudrait choisir entre

$$\begin{split} & \text{int} \times \text{int} \to \text{int} \\ & \text{int} \times \text{bool} \to \text{int} \\ & \text{bool} \times \text{int} \to \text{bool} \\ & \text{(int} \to \text{int)} \times \text{int} \to \text{int} \to \text{int} \\ & \text{etc.} \end{split}$$

de même pour les primitives opif et opfix

on ne peut pas donner de type à *opfix* de manière générale, mais on peut donner une règle de typage pour une construction let rec qui serait primitive

$$\frac{\Gamma + x : \tau_1 \vdash e_1 : \tau_1 \qquad \Gamma + x : \tau_1 \vdash e_2 : \tau_2}{\Gamma \vdash \mathsf{let} \ \mathsf{rec} \ x = e_1 \ \mathsf{in} \ e_2 : \tau_2}$$

et si on souhaite exclure les valeurs récursives, on peut modifier ainsi

$$\frac{\Gamma + (f:\tau \to \tau_1) + (x:\tau) \vdash e_1:\tau_1 \qquad \Gamma + (f:\tau \to \tau_1) \vdash e_2:\tau_2}{\Gamma \vdash \text{let rec } f \ x = e_1 \ \text{in } e_2:\tau_2}$$

différence entre règles de typage et algorithme de typage

quand on type fun $x \to e$, comment trouve-t-on le type à donner à x?

c'est toute la différence entre les **règles de typage**, qui définissent la relation ternaire

$$\Gamma \vdash e : \tau$$

et l'algorithme de typage qui vérifie qu'une certaine expression e est bien typée dans un certain environnement Γ

considérons l'approche où seuls les paramètres de fonctions sont annotés et programmons-la en OCaml

syntaxe abstraite des types

```
type typ =
    | Tint
    | Tarrow of typ * typ
    | Tproduct of typ * typ
```

le constructeur Fun prend un argument supplémentaire

```
type expression =
  | Var of string
  | Const of int
  | Op of string
  | Fun of string * typ * expression (* seul changement *)
  | App of expression * expression
  | Pair of expression * expression
  | Let of string * expression * expression
```

l'environnement Γ est réalisé par une structure persistante

en l'occurrence on utilise le module Map d'OCaml

```
module Smap = Map.Make(String)

type env = typ Smap.t
```

(performances : arbres équilibrés \Rightarrow insertion et recherche en $O(\log n)$)

pour la fonction, le type de la variable est donné

```
| Fun (x, ty, e) ->
Tarrow (ty, type_expr (Smap.add x ty env) e)
```

pour la variable locale, il est calculé

```
Let (x, e1, e2) ->
  type_expr (Smap.add x (type_expr env e1) env) e2
```

(noter l'intérêt de la persistance de env)

les seules vérifications se trouvent dans l'application

exemples

```
# type_expr
   (Let ("f",
      Fun ("x", Tint, App (Op "+", Pair (Var "x", Const 1))),
      App (Var "f", Const 2)));;
```

```
- : typ = Tint
```

```
# type_expr (Fun ("x", Tint, App (Var "x", Var "x")));;
```

```
Exception: Failure "erreur : fonction attendue".
```

```
# type_expr (App (App (Op "+", Const 1), Const 2));;
```

Exception: Failure "erreur : argument de mauvais type".

en pratique

• on ne fait pas

```
failwith "erreur de typage"
mais on indique l'origine du problème avec précision
```

on conserve les types pour les phases ultérieures du compilateur

des arbres décorés

d'une part on décore les arbres **en entrée** du typage avec une localisation dans le fichier source

```
type loc = ...
type expression =
   Var of string
   Const of int
   Op of string
  Fun of string * typ * expression
  App of expression * expression
   Pair of expression * expression
  Let of string * expression * expression
```

des arbres décorés

d'une part on décore les arbres **en entrée** du typage avec une localisation dans le fichier source

```
type loc = ...
type expression = {
  desc: desc;
 loc : loc;
and desc =
  | Var of string
  | Const of int
   Op of string
  | Fun of string * typ * expression
  | App of expression * expression
  | Pair of expression * expression
  Let of string * expression * expression
```

signaler une erreur

on déclare une exception de la forme

```
exception Error of loc * string
```

on la lève ainsi

```
let rec type_expr env e = match e.desc with
| ...
| App (e1, e2) -> begin match type_expr env e1 with
| Tarrow (ty2, ty) ->
        if type_expr env e2 <> ty2 then
        raise (Error (e2.loc, "argument de mauvais type"));
        ...
```

signaler une erreur

et on la rattrape ainsi, par exemple dans le programme principal

```
try
  let p = Parser.parse file in
  let t = Typing.program p in
  ...
with Error (loc, msg) ->
  Format.eprintf "File '%s', line ...\n" file loc;
  Format.eprintf "error: %s@." msg;
  exit 1
```

d'autre part on décore les arbres en sortie du typage avec des types

```
type texpression = {
 tdesc: tdesc;
 typ : typ;
and tdesc =
   Tvar of string
  | Tconst of int
  | Top of string
  | Tfun of string * typ * texpression
  | Tapp of texpression * texpression
  Tpair of texpression * texpression
  | Tlet
          of string * texpression * texpression
```

c'est un autre type d'expressions

typage du typage

la fonction de typage a donc un type de la forme

val type_expr: expression -> texpression

la fonction de typage reconstruit des arbres, cette fois typés

```
let rec type_expr env e =
  let d, ty = compute_type env e in
  { tdesc = d; typ = ty }
and compute_type env e = match e.desc with
  | Const n ->
      Tconst n, Tint
  | Var x ->
      Tvar x, Smap.find x env
  | Pair (e1, e2) ->
      let te1 = type_expr env e1 in
      let te2 = type_expr env e2 in
      Tpair (te1, te2), Tproduct (te1.typ, te2.typ)
```

well typed programs do not go wrong

on montre l'adéquation du typage par rapport à la sémantique à réductions

Théorème (sûreté du typage)

Si $\emptyset \vdash e : \tau$, alors la réduction de e est infinie ou se termine sur une valeur.

ou, de manière équivalente,

Théorème

 $Si \emptyset \vdash e : \tau \text{ et } e \xrightarrow{\star} e' \text{ et } e' \text{ irréductible, alors } e' \text{ est une valeur.}$

la preuve de ce théorème s'appuie sur deux lemmes

Lemme (progression)

 $Si \emptyset \vdash e : \tau$, alors soit e est une valeur, soit il existe e' tel que $e \rightarrow e'$.

Lemme (préservation)

 $Si \emptyset \vdash e : \tau \ et \ e \rightarrow e' \ alors \emptyset \vdash e' : \tau.$

Lemme (progression)

Si $\emptyset \vdash e : \tau$, alors soit e est une valeur, soit il existe e' tel que $e \rightarrow e'$.

Preuve : par récurrence sur la dérivation $\emptyset \vdash e : \tau$

supposons par exemple $e=e_1\,\,e_2\,;$ on a donc

$$\frac{\emptyset \vdash e_1 : \tau' \to \tau \quad \emptyset \vdash e_2 : \tau'}{\emptyset \vdash e_1 \ e_2 : \tau}$$

on applique l'HR à e1

- ullet si $e_1
 ightarrow e_1'$, alors $e_1 \ e_2
 ightarrow e_1' \ e_2$ (cf lemme passage au contexte)
- si e_1 est une valeur, supposons $e_1 = \operatorname{fun} x \to e_3$ (il y a aussi + etc.) on applique l'HR à e_2
 - si $e_2 o e_2'$, alors $e_1 \ e_2 o e_1 \ e_2'$ (même lemme)
 - si e_2 est une valeur, alors e_1 $e_2 o e_3[x \leftarrow e_2]$

(exercice : traiter les autres cas)

on commence par de petits lemmes faciles

Lemme (permutation)

Si $\Gamma + x : \tau_1 + y : \tau_2 \vdash e : \tau$ et $x \neq y$ alors $\Gamma + y : \tau_2 + x : \tau_1 \vdash e : \tau$ (et la dérivation a la même hauteur).

preuve : récurrence immédiate

Lemme (affaiblissement)

Si $\Gamma \vdash e : \tau$ et $x \notin dom(\Gamma)$, alors $\Gamma + x : \tau' \vdash e : \tau$ (et la dérivation a la même hauteur).

preuve : récurrence immédiate

on continue par un lemme clé

Lemme (préservation par substitution)

Si
$$\Gamma + x : \tau' \vdash e : \tau$$
 et $\Gamma \vdash e' : \tau'$ alors $\Gamma \vdash e[x \leftarrow e'] : \tau$.

preuve : par récurrence sur la dérivation $\Gamma + x : \tau' \vdash e : \tau$

- cas d'une variable e = y
 - si x = y alors $e[x \leftarrow e'] = e'$ et $\tau = \tau'$
 - si $x \neq y$ alors $e[x \leftarrow e'] = e$ et $\tau = \Gamma(y)$
- cas d'une abstraction $e = \text{fun } y \to e_1$ on peut supposer $y \neq x$, $y \not\in dom(\Gamma)$ et y non libre dans e' (α -conversion) on a $\Gamma + x : \tau' + y : \tau_2 \vdash e_1 : \tau_1$ et donc $\Gamma + y : \tau_2 + x : \tau' \vdash e_1 : \tau_1$ (permutation); d'autre part $\Gamma \vdash e' : \tau'$ et donc $\Gamma + y : \tau_2 \vdash e' : \tau'$ (affaiblissement) par HR on a donc $\Gamma + y : \tau_2 \vdash e_1[x \leftarrow e'] : \tau_1$

et donc $\Gamma \vdash (\text{fun } y \rightarrow e_1)[x \leftarrow e'] : \tau_2 \rightarrow \tau_1$, *i.e.* $\Gamma \vdash e[x \leftarrow e'] : \tau$

(exercice : traiter les autres cas)

on peut enfin montrer

Lemme (préservation)

$$Si \emptyset \vdash e : \tau \ et \ e \rightarrow e' \ alors \emptyset \vdash e' : \tau.$$

preuve : par récurrence sur la dérivation $\emptyset \vdash e : \tau$

• cas e =let $x = e_1$ in e_2

$$\frac{\emptyset \vdash e_1 : \tau_1 \qquad x : \tau_1 \vdash e_2 : \tau_2}{\emptyset \vdash \mathsf{let} \ x = e_1 \ \mathsf{in} \ e_2 : \tau_2}$$

- si $e_1 o e_1'$, par HR on a $\emptyset \vdash e_1' : au_1$ et donc $\emptyset \vdash$ let $x = e_1'$ in $e_2 : au_2$
- si e_1 est une valeur et $e' = e_2[x \leftarrow e_1]$ alors on applique le lemme de préservation par substitution
- cas $e = e_1 e_2$
 - si $e_1 o e_1'$ ou si e_1 valeur et $e_2 o e_2'$ alors on utilise l'HR
 - si $e_1 = \text{fun } x \to e_3$ et e_2 valeur alors $e' = e_3[x \leftarrow e_2]$ et on applique là encore le lemme de substitution

on peut maintenant prouver le théorème facilement

Théorème (sûreté du typage)

 $Si \emptyset \vdash e : \tau \text{ et } e \xrightarrow{\star} e' \text{ et } e' \text{ irréductible, alors } e' \text{ est une valeur.}$

preuve : on a $e \to e_1 \to \cdots \to e'$ et par applications répétées du lemme de préservation, on a donc $\emptyset \vdash e' : \tau$

par le lemme de progression, e' se réduit ou est une valeur

c'est donc une valeur

polymorphisme

il est contraignant de donner un type unique à fun $x \to x$ dans

let
$$f = \text{fun } x \rightarrow x \text{ in } \dots$$

de même, on aimerait pouvoir donner \ll plusieurs types \gg aux primitives telles que fst ou snd

une solution : le polymorphisme paramétrique

polymorphisme paramétrique

on étend l'algèbre des types :

variables de types libres

on note $\mathcal{L}(\tau)$ l'ensemble des variables de types libres dans au, défini par

$$egin{array}{lll} \mathcal{L}(ext{int}) &=& \emptyset \ \mathcal{L}(lpha) &=& \{lpha\} \ \mathcal{L}(au_1
ightarrow au_2) &=& \mathcal{L}(au_1) \cup \mathcal{L}(au_2) \ \mathcal{L}(au_1 imes au_2) &=& \mathcal{L}(au_1) \cup \mathcal{L}(au_2) \ \mathcal{L}(orall lpha. au) &=& \mathcal{L}(au) \setminus \{lpha\} \end{array}$$

pour un environnement Γ, on définit aussi

$$\mathcal{L}(\Gamma) = \bigcup_{x \in dom(\Gamma)} \mathcal{L}(\Gamma(x))$$

substitution de type

on note $\tau[\alpha \leftarrow \tau']$ la substitution de α par τ' dans τ , définie par

$$\begin{array}{rcl} \inf[\alpha\leftarrow\tau'] &=& \inf\\ \alpha[\alpha\leftarrow\tau'] &=& \tau'\\ \beta[\alpha\leftarrow\tau'] &=& \beta & \text{si } \beta\neq\alpha\\ (\tau_1\to\tau_2)[\alpha\leftarrow\tau'] &=& \tau_1[\alpha\leftarrow\tau']\to\tau_2[\alpha\leftarrow\tau']\\ (\tau_1\times\tau_2)[\alpha\leftarrow\tau'] &=& \tau_1[\alpha\leftarrow\tau']\times\tau_2[\alpha\leftarrow\tau']\\ (\forall\alpha.\tau)[\alpha\leftarrow\tau'] &=& \forall\alpha.\tau\\ (\forall\beta.\tau)[\alpha\leftarrow\tau'] &=& \forall\beta.\tau[\alpha\leftarrow\tau'] & \text{si } \beta\neq\alpha \end{array}$$

les règles sont exactement les mêmes qu'auparavant, plus

$$\frac{\Gamma \vdash e : \tau \qquad \alpha \not\in \mathcal{L}(\Gamma)}{\Gamma \vdash e : \forall \alpha. \tau}$$

et

$$\frac{\Gamma \vdash e : \forall \alpha.\tau}{\Gamma \vdash e : \tau[\alpha \leftarrow \tau']}$$

le système obtenu s'appelle le système F (J.-Y. Girard / J. C. Reynolds)

exemple

```
 \frac{ x : \alpha \vdash x : \alpha }{ \vdash \text{fun } x \to x : \alpha \to \alpha } \quad \frac{ \frac{ \dots \vdash f : \forall \alpha . \alpha \to \alpha }{ \dots \vdash f : \text{int} \to \text{int} } : }{ \dots \vdash f : \text{int} \to \text{int} } : \\  \frac{ \vdash \text{fun } x \to x : \forall \alpha . \alpha \to \alpha }{ \vdash \text{fun } x \to x : \forall \alpha . \alpha \to \alpha } \quad \frac{ \dots \vdash f : \text{int} \to \text{int} }{ f : \forall \alpha . \alpha \to \alpha \vdash (f : 1, f : 1,
```

on peut maintenant donner un type satisfaisant aux primitives

$$fst: \forall \alpha. \forall \beta. \alpha \times \beta \rightarrow \alpha$$

$$\mathit{snd}: \ \forall \alpha. \forall \beta. \alpha \times \beta \rightarrow \beta$$

$$\textit{opif}: \ \forall \alpha. \texttt{bool} \times \alpha \times \alpha \rightarrow \alpha$$

opfix:
$$\forall \alpha.(\alpha \to \alpha) \to \alpha$$

on peut construire une dérivation de

$$\Gamma \vdash \text{fun } x \to x \ x : (\forall \alpha. \alpha \to \alpha) \to (\forall \alpha. \alpha \to \alpha)$$

(exercice : le faire)

la condition $\alpha \notin \mathcal{L}(\Gamma)$ dans la règle

$$\frac{\Gamma \vdash e : \tau \qquad \alpha \not\in \mathcal{L}(\Gamma)}{\Gamma \vdash e : \forall \alpha.\tau}$$

est cruciale

sans elle, on aurait

$$\frac{\Gamma + x : \alpha \vdash x : \alpha}{\Gamma + x : \alpha \vdash x : \forall \alpha.\alpha}$$
$$\Gamma \vdash \text{fun } x \to x : \alpha \to \forall \alpha.\alpha$$

et on accepterait donc le programme

(fun
$$x \rightarrow x$$
) 1 2

une mauvaise nouvelle

pour des termes sans annotations, les deux problèmes

- **inférence** : étant donnée e, existe-t-il τ tel que $\vdash e : \tau$?
- **vérification** : étant donnés e et τ , a-t-on $\vdash e$: τ ?

ne sont pas décidables

J. B. Wells. Typability and type checking in the second-order lambda-calculus are equivalent and undecidable, 1994.

pour obtenir une inférence de types décidable, on va restreindre la puissance du système F

⇒ le système de Hindley-Milner, utilisé dans OCaml, SML, Haskell, ...

on limite la quantification ∀ en tête des types (quantification prénexe)

l'environnement Γ associe un schéma de type à chaque identificateur et la relation de typage a maintenant la forme $\Gamma \vdash e : \sigma$

dans Hindley-Milner, les types suivants sont toujours acceptés

$$\begin{array}{l} \forall \alpha.\alpha \rightarrow \alpha \\ \forall \alpha. \forall \beta.\alpha \times \beta \rightarrow \alpha \\ \forall \alpha. \texttt{bool} \times \alpha \times \alpha \rightarrow \alpha \\ \forall \alpha. (\alpha \rightarrow \alpha) \rightarrow \alpha \end{array}$$

mais plus les types tels que

$$(\forall \alpha. \alpha \to \alpha) \to (\forall \alpha. \alpha \to \alpha)$$

notation en OCaml

note : dans la syntaxe d'OCaml, la quantification prénexe est implicite

$$\forall \alpha. \forall \beta. \alpha \times \beta \rightarrow \alpha$$

$$\forall \alpha. \forall \beta. (\alpha \to \beta \to \alpha) \to \alpha \to \beta \text{ list} \to \alpha$$

on note que seule la construction let permet d'introduire un type polymorphe dans l'environnement

$$\frac{\Gamma \vdash e_1 : \sigma_1 \qquad \Gamma + x : \sigma_1 \vdash e_2 : \sigma_2}{\Gamma \vdash \text{let } x = e_1 \text{ in } e_2 : \sigma_2}$$

en particulier, on peut toujours typer

let
$$f = \text{fun } x \rightarrow x \text{ in } (f 1, f \text{ true})$$

avec $f: \forall \alpha.\alpha \rightarrow \alpha$ dans le contexte pour typer $(f \ 1, f \ \text{true})$

en revanche, la règle de typage

$$\frac{\Gamma + x : \tau_1 \vdash e : \tau_2}{\Gamma \vdash \text{fun } x \rightarrow e : \tau_1 \rightarrow \tau_2}$$

n'introduit pas un type polymorphe (sinon $au_1 o au_2$ serait mal formé)

en particulier, on ne peut plus typer

fun
$$x \rightarrow x x$$

considérations algorithmiques

pour programmer une vérification ou une inférence de type, on procède par récurrence sur la structure du programme

or, pour une expression donnée, trois règles peuvent s'appliquer : la règle du système monomorphe, la règle

$$\frac{\Gamma \vdash e : \sigma \qquad \alpha \not\in \mathcal{L}(\Gamma)}{\Gamma \vdash e : \forall \alpha. \sigma}$$

ou encore la règle

$$\frac{\Gamma \vdash e : \forall \alpha.\sigma}{\Gamma \vdash e : \sigma[\alpha \leftarrow \tau]}$$

comment choisir? va-t-on devoir procéder par essais/erreurs?

nous allons modifier la présentation du système de Hindley-Milner pour qu'il soit **dirigé par la syntaxe** (*syntax-directed*), *i.e.*, pour toute expression, au plus une règle s'applique

les règles ont la même puissance d'expression : tout terme clos est typable dans un système si et seulement si il est typable dans l'autre

$$\frac{\tau \leq \Gamma(x)}{\Gamma \vdash x : \tau} \qquad \frac{\tau \leq type(op)}{\Gamma \vdash n : \mathtt{int}} \dots \qquad \frac{\tau \leq type(op)}{\Gamma \vdash op : \tau}$$

$$\frac{\Gamma + x : \tau_1 \vdash e : \tau_2}{\Gamma \vdash \text{fun } x \rightarrow e : \tau_1 \rightarrow \tau_2} \qquad \frac{\Gamma \vdash e_1 : \tau' \rightarrow \tau \quad \Gamma \vdash e_2 : \tau'}{\Gamma \vdash e_1 \; e_2 : \tau}$$

$$\frac{\Gamma \vdash e_1 : \tau_1 \quad \Gamma \vdash e_2 : \tau_2}{\Gamma \vdash (e_1, e_2) : \tau_1 \times \tau_2} \qquad \frac{\Gamma \vdash e_1 : \tau_1 \quad \Gamma + x : \textit{Gen}(\tau_1, \Gamma) \vdash e_2 : \tau_2}{\Gamma \vdash \text{let } x = e_1 \text{ in } e_2 : \tau_2}$$

deux opérations apparaissent

• l'instanciation, dans la règle

$$\frac{\tau \le \Gamma(x)}{\Gamma \vdash x : \tau}$$

la relation $\tau \leq \sigma$ se lit « τ est une instance de σ » et est définie par

$$\tau \leq \forall \alpha_1...\alpha_n.\tau' \quad \text{ssi} \quad \exists \tau_1...\exists \tau_n. \ \tau = \tau'[\alpha_1 \leftarrow \tau_1,...,\alpha_n \leftarrow \tau_n]$$

exemple : int \times bool \rightarrow int $\leq \forall \alpha. \forall \beta. \alpha \times \beta \rightarrow \alpha$

• et la généralisation, dans la règle

$$\frac{\Gamma \vdash e_1 : \tau_1 \qquad \Gamma + x : \textit{Gen}(\tau_1, \Gamma) \vdash e_2 : \tau_2}{\Gamma \vdash \texttt{let } x = e_1 \; \texttt{in} \; e_2 : \tau_2}$$

οù

$$Gen(\tau_1, \Gamma) \stackrel{\text{def}}{=} \forall \alpha_1 ... \forall \alpha_n . \tau_1 \quad \text{où} \quad \{\alpha_1, ..., \alpha_n\} = \mathcal{L}(\tau_1) \setminus \mathcal{L}(\Gamma)$$

exemple

$$\frac{\alpha \leq \alpha}{\Gamma + x : \alpha \vdash x : \alpha} \qquad \frac{\frac{\inf \to \inf \leq \forall \alpha. \alpha \to \alpha}{\Gamma' \vdash f : \inf \to \inf} : \frac{\frac{bool \to bool \leq \forall \alpha. \alpha \to \alpha}{\Gamma' \vdash f : bool \to bool} :}{\Gamma' \vdash f : \inf} \qquad \frac{\Gamma' \vdash f : \inf}{\Gamma' \vdash f : \inf} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \inf} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \inf} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \inf} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \inf} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \inf} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \inf} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \inf} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \prod} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \prod} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \prod} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \prod} : \frac{\Gamma' \vdash f : \prod}{\Gamma' \vdash f : \prod} :$$

avec $\Gamma' = \Gamma + f : Gen(\alpha \to \alpha, \Gamma) = \Gamma + f : \forall \alpha.\alpha \to \alpha$ si α est choisie non libre dans Γ

inférence de types pour mini-ML

pour inférer le type d'une expression, il reste des problèmes

- dans fun $x \rightarrow e$, quel type donner à x?
- pour une variable x, quelle instance de $\Gamma(x)$ choisir?

il existe une solution : l'algorithme W (Milner, Damas, Tofte)

l'algorithme W

deux idées

- on utilise de nouvelles variables de types pour représenter les types inconnus
 - pour le type de x dans fun $x \to e$
 - pour instancier les variables du schéma $\Gamma(x)$
- on détermine la valeur de ces variables plus tard, par unification entre types au moment du typage de l'application

soient deux types τ_1 et τ_2 contenant des variables de types $\alpha_1, \ldots, \alpha_n$ existe-t-il une instanciation f des variables α_i telle que $f(\tau_1) = f(\tau_2)$? on appelle cela l'unification

exemple 1:

$$\begin{array}{l} \tau_1 = \alpha \times \beta \to \mathtt{int} \\ \tau_2 = \mathtt{int} \times \mathtt{bool} \to \gamma \\ \mathtt{solution}: \quad \alpha = \mathtt{int} \ \land \ \beta = \mathtt{bool} \ \land \ \gamma = \mathtt{int} \end{array}$$

exemple 2:

$$au_1 = \alpha imes \operatorname{int} \to \alpha imes \operatorname{int} \\ au_2 = \gamma \to \gamma \\ ext{solution:} \quad \gamma = \alpha imes \operatorname{int}$$

unification

exemple 3:

$$au_1 = lpha
ightarrow ext{int} \ au_2 = eta imes \gamma \ ext{pas de solution}$$

exemple 4:

$$au_1 = lpha
ightarrow ext{int} \ au_2 = lpha$$
 pas de solution

pseudo-code de l'unification

 $unifier(\tau_1, \tau_2)$ détermine s'il existe une instance des variables de types de τ_1 et τ_2 telle que $\tau_1 = \tau_2$

$$\begin{aligned} \textit{unifier}(\tau,\tau) &= \mathsf{succès} \\ \textit{unifier}(\tau_1 \to \tau_1',\tau_2 \to \tau_2') &= \textit{unifier}(\tau_1,\tau_2) \;; \; \textit{unifier}(\tau_1',\tau_2') \\ \textit{unifier}(\tau_1 \times \tau_1',\tau_2 \times \tau_2') &= \textit{unifier}(\tau_1,\tau_2) \;; \; \textit{unifier}(\tau_1',\tau_2') \\ \textit{unifier}(\alpha,\tau) &= \mathsf{si} \; \alpha \not\in \mathcal{L}(\tau), \; \mathsf{remplacer} \; \alpha \; \mathsf{par} \; \tau \; \mathsf{partout} \\ &\mathsf{sinon}, \; \mathsf{\'echec} \\ &\mathsf{unifier}(\tau,\alpha) &= \mathsf{unifier}(\alpha,\tau) \\ &\mathsf{unifier}(\tau_1,\tau_2) &= \mathsf{\'echec} \; \mathsf{dans} \; \mathsf{tous} \; \mathsf{les} \; \mathsf{autres} \; \mathsf{cas} \end{aligned}$$

(pas de panique : on le fera en TD)

l'idée de l'algorithme W sur un exemple

considérons l'expression $[\mathtt{fun} \ x o + (\mathit{fst} \ x, 1)]$

- à x on donne le type α_1 , nouvelle variable de type
- la primitive + a le type int \times int \rightarrow int
- typons l'expression ($fst \times, 1$)
 - fst a pour type le schéma $\forall \alpha. \forall \beta. \alpha \times \beta \rightarrow \alpha$
 - on lui donne donc le type $\alpha_2 imes \beta_1 o \alpha_2$ pour deux nouvelles variables
 - l'application fst x impose d'unifier α_1 et $\alpha_2 \times \beta_1$, $\Rightarrow \alpha_1 = \alpha_2 \times \beta_1$
- (fst x, 1) a donc le type $\alpha_2 \times \text{int}$
- l'application $+(\mathit{fst}\ x,1)$ unifie int \times int et $lpha_2 \times$ int, $\Rightarrow lpha_2 =$ int

au final, on obtient le type $\mathtt{int} \times \beta_1 \to \mathtt{int}$, et en généralisant on obtient finalement $\forall \beta.\mathtt{int} \times \beta \to \mathtt{int}$

pseudo-code de l'algorithme W

on définit une fonction W qui prend en arguments un environnement Γ et une expression e et renvoie le type inféré pour e

- si e est une variable x, renvoyer une instance triviale de Γ(x)
- si e est une constante c, renvoyer une instance triviale de son type (penser à [] : α list)
- si e est une primitive op, renvoyer une instance triviale de son type
- si e est une paire (e_1, e_2) , calculer $\tau_1 = W(\Gamma, e_1)$ calculer $\tau_2 = W(\Gamma, e_2)$ renvoyer $\tau_1 \times \tau_2$

l'algorithme W

- si e est une fonction fun $x \to e_1$, soit α une nouvelle variable calculer $\tau = W(\Gamma + x : \alpha, e_1)$ renvoyer $\alpha \to \tau$
- si e est une application e_1 e_2 , calculer $\tau_1 = W(\Gamma, e_1)$ calculer $\tau_2 = W(\Gamma, e_2)$ soit α une nouvelle variable unifier $(\tau_1, \tau_2 \to \alpha)$ renvoyer α
- si e est let $x = e_1$ in e_2 , calculer $\tau_1 = W(\Gamma, e_1)$ renvoyer $W(\Gamma + x : Gen(\tau_1, \Gamma), e_2)$

Théorème (Damas, Milner, 1982)

L'algorithme W est correct, complet et détermine le type principal :

- si $W(\emptyset, e) = \tau$ alors $\emptyset \vdash e : \tau$
- $si \emptyset \vdash e : \tau \ alors \ \tau \leq \forall \bar{\alpha}.W(\emptyset,e)$

Théorème (sûreté du typage)

Le système de Hindley-Milner est sûr. (Si $\emptyset \vdash e : \tau$, alors la réduction de e est infinie ou se termine sur une valeur.)

considérations algorithmiques

il existe plusieurs façons de réaliser l'unification

• en manipulant explicitement une substitution

```
type tvar = int
type subst = typ TVmap.t
```

en utilisant des variables de types destructives

```
type tvar = { id: int; mutable def: typ option; }
```

il existe également plusieurs façons de coder l'algorithme W

• avec des schémas explicites et en calculant $Gen(\tau, \Gamma)$

```
type schema = { tvars: TVset.t; typ: typ; }
```

avec des niveaux

$$\frac{\Gamma \vdash_{n+1} e_1 : \tau_1 \qquad \Gamma + x : (\tau_1, n) \vdash_n e_2 : \tau_2}{\Gamma \vdash_n \text{let } x = e_1 \text{ in } e_2 : \tau_2}$$

cf. TD 4

extensions

on peut étendre mini-ML de nombreuses façons

- récursion
- types construits (*n*-uplets, listes, types sommes et produits)
- références

comme déjà expliqué, on peut définir

$$\begin{array}{l} \texttt{let rec } f \; \mathsf{x} = \mathsf{e}_1 \; \texttt{in } \mathsf{e}_2 \stackrel{\texttt{def}}{=} \\ \\ \texttt{let } f = \mathit{opfix} \; (\texttt{fun } f \to \texttt{fun } \mathsf{x} \to \mathsf{e}_1) \; \texttt{in } \mathsf{e}_2 \end{array}$$

οù

opfix :
$$\forall \alpha. \forall \beta. ((\alpha \rightarrow \beta) \rightarrow (\alpha \rightarrow \beta)) \rightarrow (\alpha \rightarrow \beta)$$

de manière équivalente, on peut donner la règle

$$\frac{\Gamma + f : \tau \to \tau_1 + x : \tau \vdash e_1 : \tau_1 \qquad \Gamma + f : \underline{\textit{Gen}}(\tau \to \tau_1, \Gamma) \vdash e_2 : \tau_2}{\Gamma \vdash \mathtt{let} \; \mathtt{rec} \; f \; x = e_1 \; \mathtt{in} \; e_2 : \tau_2}$$

on a déjà vu les paires

les listes ne posent pas de difficulté

$$\begin{array}{ll} \textit{nil}: & \forall \alpha.\alpha \textit{ list} \\ \textit{cons}: & \forall \alpha.\alpha \times \alpha \textit{ list} \rightarrow \alpha \textit{ list} \end{array}$$

$$\frac{\Gamma \vdash e_1 : \tau_1 \ \textit{list} \qquad \Gamma \vdash e_2 : \tau \qquad \Gamma + x : \tau_1 + y : \tau_1 \ \textit{list} \vdash e_3 : \tau}{\Gamma \vdash \texttt{match} \ e_1 \ \texttt{with} \ \textit{nil} \rightarrow e_2 \mid \textit{cons}(x,y) \rightarrow e_3 : \tau}$$

se généralise aisément aux types sommes et produits

pour les références, on peut naïvement penser qu'il suffit d'ajouter les primitives

 $ref: \forall \alpha.\alpha \rightarrow \alpha \ ref$

 $!: \forall \alpha. \alpha \ ref \rightarrow \alpha$

 $:=: \forall \alpha. \alpha \ ref \rightarrow \alpha \rightarrow unit$

malheureusement, c'est incorrect!

let
$$r = ref (fun \ x \to x)$$
 in $r : \forall \alpha.(\alpha \to \alpha) \ ref$
let $_- = r := (fun \ x \to x + 1)$ in $!r$ true boum !

c'est le problème dit des références polymorphes

pour contourner ce problème, il existe une solution extrêmement simple, à savoir une restriction syntaxique de la construction let

Définition (value restriction, Wright 1995)

Un programme satisfait le critère de la value restriction si toute sous-expression let est de la forme

let
$$x = v_1$$
 in e_2

 $où v_1$ est une valeur.

on ne peut plus écrire

let
$$r = ref (fun x \rightarrow x) in ...$$

mais on peut écrire en revanche

$$(\text{fun } r \to \dots) (ref (\text{fun } x \to x))$$

où le type de r n'est pas généralisé

en pratique, on continue d'écrire let r = ref ... in ... mais le type de r n'est pas généralisé

en OCaml, une variable non généralisée est de la forme '_a

let
$$x = ref (fun x \rightarrow x);;$$

la value restriction est également légèrement relâchée pour autoriser des expressions sûres, telles que des applications de constructeurs

$$# let 1 = [fun x -> x];;$$

il reste quelques petits désagréments

```
# let id x = x;;
```

$$-: int = 1$$

This expression has type bool but is here used with type int

- # f;;
- : int -> int = <fun>

la solution : expanser pour faire apparaître une fonction, i.e., une valeur

$$let$$
 f x = id id x;;

$$val f : 'a \rightarrow 'a = \langle fun \rangle$$

(on parle d' η -expansion)

en présence du système de modules, la réalité est plus complexe encore

étant donné un module M

```
module M : sig
  type 'a t
  val create : int -> 'a t
end
```

ai-je le droit de généraliser le type de M. create 17?

la réponse dépend du type 'a t : non pour une table de hachage, oui pour une liste pure, etc.

en OCaml, une indication de variance permet de distinguer les deux

```
type +'a t (* on peut généraliser *)
type 'a u (* on ne peut pas *)
```

lire Relaxing the value restriction, J. Garrigue, 2004

deux ouvrages en rapport avec ce cours

- Benjamin C. Pierce, *Types and Programming Languages* (également en rapport avec le cours 3)
- Xavier Leroy et Pierre Weis, Le langage Caml (le dernier chapitre explique l'inférence avec les niveaux)

la suite

- TD 4
 - unification et algorithme W
- prochain cours
 - analyse lexicale

remerciements

ce cours reprend des notes de cours de Xavier Leroy (cours de remise à niveau « Programmation, sémantique, typage »)